

mergecalib

省内人群合并与比例区间校准 R 包

版本：0.1.0 日期：2026年6月22日

用途：在不跨省合并的前提下，将零样本或小样本细分人群并入同省其他人群，使省级及全国指定人群的 A、B、C、D 加权比例尽可能进入目标区间，并输出完整、可复现、可审计的合并方案。

核心保证：最终输出的每一个合并簇都满足 $\text{final_n} > 0$ 。若某省全部样本量均为 0，程序会明确判定结构性无解，不会生成伪结果。

目录与阅读建议

- 1. 问题定义与适用范围
- 2. 数学模型
- 3. 零样本人群硬约束
- 4. 数据与目标表格式
- 5. 安装与快速开始
- 6. 候选簇生成
- 7. MILP 与分层优化
- 8. 目标不可行与最小放宽量
- 9. 输出表与审计
- 10. 参数建议与性能
- 11. 边界情况
- 12. 完整示例与结果解释

第一次使用可先阅读第 3、4、5、9 节；需要审核算法时重点阅读第 2、6、7、8 节。

1. 问题定义与适用范围

每行输入数据代表一个原始细分人群，通常由省份、性别、城乡、年龄段和教育水平共同界定。每行还包含样本量 n 、该人群总权重 W ，以及 A、B、C、D 四个档次人数。

程序只在省内合并原始人群。合并不会删除原始人口属性和档次标签，而是让同一最终簇内所有观察样本共享一个新的单位权重。

- 省级目标：每个省的 ABCD 加权比例进入给定范围。
- 全国目标：全国性别、城乡、年龄、教育边际人群或任意交叉人群的 ABCD 加权比例进入给定范围。
- 输出：最终正样本合并簇、原始人群映射、逐步合并方案、各类比例结果及审计报告。

2. 数学模型

2.1 合并簇的共同单位权重

对候选簇 C ，定义 $N_C = \sum n_i$ ， $W_C = \sum W_i$ 。只允许 $N_C > 0$ 的候选簇。簇内共同单位权重为：

$$\bar{w}_C = W_C / N_C$$

档次 k 的加权人数为 $\bar{w}_C \times \sum c_{ik}$ 。由于候选簇生成后 N_C 、 W_C 和档次人数均为常数，所以每个候选簇对任何目标的贡献都是已知常数。

2.2 集合划分变量

每个候选簇 C 对应一个二元变量 x_C 。 $x_C=1$ 表示选择该簇。对每个原始人群 i ，约束 $\sum_{\{C \text{ 包含 } i\}} x_C = 1$ ，保证每个原始人群恰好出现一次，既不遗漏也不重复。

2.3 比例区间线性化

对目标人群 h 和档次 k ，要求 $L_{hk} \leq Y_{hk} / D_h \leq U_{hk}$ 。由于 $D_h > 0$ ，可以改写为 $Y_{hk} - L_{hk} D_h \geq 0$ 和 $Y_{hk} - U_{hk} D_h \leq 0$ 。 Y 与 D 都是候选簇选择变量的线性组合，因此整个问题为混合整数线性规划。

3. 零样本人群硬约束

这是本包区别于普通合并脚本的核心。程序从候选生成、模型求解到结果审计共设置三道防线。

3.1 候选层

- $n=0$ 的原始人群不能形成单独候选簇。
- 所有候选簇必须满足 $n_{\text{total}} > 0$ 。
- - 每个零样本人群按人口学距离、正样本人群规模和固定编号顺序，确定性地分配给最近的正样本锚点。
- 每省自动加入一套“正样本锚点 + 所属零样本人群”的完整吸收分区。

3.2 模型层

集合划分约束只允许从正样本候选簇中选择，所以模型在数学上不可能输出 $n_{\text{total}}=0$ 的最终簇。

3.3 审计层

求解结束后，`audit_merge_fit()` 再检查全部 `final_n`。如果发现任何 `final_n ≤ 0`，程序终止并报告内部错误，不返回不合格结果。

若某省全部原始人群均为 $n=0$ ，在禁止跨省合并的规则下不存在正样本锚点，因此程序在求解前直接报“结构性无解”。

4. 数据与目标表格式

4.1 默认数据字段

字段	含义	硬性要求
cell_id	原始人群唯一编号	唯一、非缺失
province	省份	非缺失
sex / urban / age / education	人群界定变量	非缺失
n	样本量	非负整数
weight	人群总权重	非负； $n > 0$ 时必须 > 0
A/B/C/D	档次人数	非负整数，行和等于 n

4.2 权重的含义

weight 必须是原始人群的总权重。如果现有字段是平均个体权重，应先换算为 $\text{weight} = n \times \text{平均个体权重}$ 。n=0 时允许 $\text{weight} > 0$ ，这部分权重将在合并后分配到同簇实际样本。

4.3 目标表

每行控制一个档次，必须包含 target_id、grade、lower、upper。人口字段填具体值表示筛选，NA 或 “*” 表示通配。

```
target_id grade lower upper province sex urban age education
北京      A  0.25 0.30 北京    NA NA  NA NA
全国男性  A  0.24 0.29 NA      男 NA  NA NA
```

5. 安装与快速开始

5.1 安装

```
install.packages("highs")
install.packages("mergecalib_0.1.0.tar.gz",
  repos = NULL, type = "source")
```

5.2 完整示例

```
library(mergecalib)

spec <- merge_spec(
  level_orders = list(
    age = c("18-39", "40+"),
    education = c("low", "high")
  )
)

dat <- example_merge_data()
targets <- example_merge_targets(dat, spec)
fit <- fit_merge_calibration(dat, targets, spec)

print(fit)
summary(fit)
```

默认使用 HiGHS 求解器、单线程、固定随机种子和关闭并行分支，以提高可复现性。

6. 候选簇生成

候选空间不直接枚举一个省内全部子集，而是按人口学距离生成有限的近邻组合，并按层级逐步扩大。

层级	最大普通簇规模	近邻数	用途
local_pairs	2	4	优先寻找最简单两两合并
local_small	3	6	允许局部三人群簇
broad	4	8	扩大跨维度组合
widest	6	12	最宽默认空间，并加入全省候选

年龄和教育按有序距离计算；性别与城乡按是否相同计算。建议始终通过 `level_orders` 明确年龄段和教育水平的顺序，避免字符排序造成不符合业务的邻近关系。

7. MILP 与分层优化

7.1 可行性优先

程序先在最窄候选层级检查严格目标是否可行，只有无解时才扩大候选空间。这样可以避免一开始构造过多候选簇。

7.2 分层目标

- 第一层：最小化被重新赋权的样本量 `moved_n`。
- 第二层：最小化人口学距离 `demo_distance`。
- 第三层：最小化 ABCD 分布异质性 `heterogeneity`。
- 第四层：最小化单位权重变化 `weight_distortion`。
- 第五层：最小化合并次数 `merge_count`。

每完成一层，就把该层最优值加上极小数值容差作为下一层的硬约束。因此低优先级目标不会牺牲高优先级目标。

8. 目标不可行与最小放宽量

只有合并操作时，目标范围不一定可达。严格目标在全部候选层级无解后，程序固定一个统一放宽量 δ ，将区间改为 $[\max(0, L - \delta), \min(1, U + \delta)]$ ，并通过二分搜索求最小可行 δ 。

```
fit$delta
target_results(fit)[, c(
  "target_id", "grade", "lower", "upper",
  "effective_lower", "effective_upper", "final_proportion"
)]
```

若在 `max_delta` 内仍无解，程序停止。此时应检查目标逻辑、扩大候选范围或重新审视禁止跨省合并等业务限制。

9. 输出表与审计

函数	主要内容
<code>cell_map(fit)</code>	每个原始人群所属最终簇、锚点、合并顺序和最终单位权重
<code>merge_plan(fit)</code>	按小样本优先排列的逐步合并操作
<code>final_cells(fit)</code>	最终簇汇总； <code>final_n</code> 全部大于 0
<code>target_results(fit)</code>	初始比例、最终比例、原始和有效目标区间、状态
<code>province_results(fit)</code>	所有省份的 ABCD 初始与最终比例
<code>national_cell_results(fit)</code>	全国非零观察样本细分人群结果
<code>audit_merge_fit(fit)</code>	零样本、覆盖、守恒、目标和模型约束审计

原始 $n=0$ 行仍会保留在 `cell_map`

中，便于追踪其去向；但它们不再是独立最终人群。真正的最终人群应查看 `final_cells`。

10. 参数建议与性能

- 每省约 100 个原始人群时，优先使用默认层级。
- 目标较宽时，通常 `local_pairs` 或 `local_small` 即可求解。
- 目标很紧时，可提高 `max_neighbors`、`max_cluster_size` 和 `max_combinations_per_cell`。
- `max_unit_weight` 与 `max_weight_ratio` 可限制极端权重，但过紧可能使零样本人群无法被吸收。
- 生产环境建议保留 `threads=1`；需要速度且接受潜在求解路径差异时再增加线程。

```
fit <- fit_merge_calibration(  
  dat, targets, spec,  
  candidate_control = list(  
    max_weight_ratio = 5  
  ),  
  solver_control = list(  
    time_limit = 600,  
    mip_rel_gap = 1e-7  
  )  
)
```

11. 边界情况

11.1 某省全部 $n=0$

结构性无解。因为禁止跨省合并，同省不存在任何正样本锚点。

11.2 目标人群观察样本总量为 0

不可估计。合并只能改变共同权重，不能创造该人口属性下的观察样本。

11.3 $n=0$ 且 $weight>0$

允许输入，但必须并入正样本簇。其权重将通过簇共同单位权重分配到实际观察样本。

11.4 严格区间无解

程序报告最小统一放宽量；超过 `max_delta` 仍无解则停止。

11.5 目标可行不等于统计无偏

合并结果仍需结合抽样设计、非响应机制、人口学合理性和业务含义审查。尤其要关注跨越多个维度的大簇、过大的单位权重和高 ABCD 异质性。

12. 完整结果检查清单

- `audit_merge_fit(fit)$valid` 为 TRUE。
- `final_cells(fit)$final_n` 全部大于 0。
- 样本量与总权重在合并前后守恒。
- `target_results(fit)$status` 全部为 within。
- 若 `fit$delta>0`，明确记录目标区间被放宽的幅度。
- 检查 `max_weight_ratio`、`heterogeneity` 和 `cluster_size` 较大的最终簇。
- 保存 `cell_map` 和 `merge_plan`，保证结果可复核。

建议将 `cell_map`、`merge_plan`、`final_cells`、`target_results`、`province_results` 和 `audit_merge_fit` 的结果一并归档。

附录：最小工作代码

```
library(mergecalib)

spec <- merge_spec(
  province = "province", id = "cell_id",
  n = "n", weight = "weight",
  grades = c(A="A", B="B", C="C", D="D"),
  groups = c(sex="sex", urban="urban",
    age="age", education="education"),
  ordered_groups = c("age", "education"),
  level_orders = list(
    age = c("18-29", "30-39", "40-49", "50-59", "60+"),
    education = c("小学及以下", "初中", "高中", "大专", "本科及以上")
  )
)

validate_merge_data(dat, targets, spec)
fit <- fit_merge_calibration(dat, targets, spec)
stopifnot(audit_merge_fit(fit)$valid)
stopifnot(all(final_cells(fit)$final_n > 0))
```